



FACULTÉ DES SCIENCES
DÉPARTEMENT DE MATHÉMATIQUES

MASTER : ANALYSE MATHÉMATIQUE STATISTIQUE GÉOMÉTRIE ET
APPLICATION

Rapport de Projet

Statistique d'ordre

Présenté par :
Zakariae boujham

prof :
Mohammed EL ARROUCHI

2020

Introduction

Le but de ce projet est double. D'une part, il s'agit de se familiariser avec le logiciel R, et d'autre part, de retrouver la loi de probabilité de X à partir des observations $(x_1; \dots; x_{500})$. On suppose tout d'abord que la loi de probabilité de X appartient à un ensemble des lois de probabilités classiques dont la liste est donnée ci-dessous avec leurs codes sur R.

Loi	f	F	Générateur aléatoire
bêta	dbeta	pbeta	rbeta
logistique	dlogis	plogis	rlogis
gamma	dgamma	pgamma	rgamma
normale	dnorm	pnorm	rnorm
log-normale	dlnorm	plnorm	rlnorm
de Weibull	dweibull	pweibull	rweibull
de Pareto	dpareto	ppareto	rpareto
de Cauchy	dcauchy	pcauchy	rcauchy

Question1

La statistique descriptive consiste à déterminer les paramètres de position (Minimum, Premier quartile, la Médiane, troisième quartile et le maximum) et les paramètres de dispersion (variance, écart type, étendu et écart inter-quartile).

Après l'importation des données dans logiciel R, les commandes suivantes nous aident à calculer ces paramètres :

- summary(x)
- var(x)
- sd(x)
- IQR(x)
- range(x)[2]-range(x)[1]

On obtient les résultats suivants :

Minimum	Premier quartile	Médiane	Moyenne	troisième quartile	Maximum
0.07595232883	1.64151475524	3.09839680914	5.10256923845	5.93518542451	86.55350116641

variance	écart type	étendu	écart inter-quartile
49.512009209824	7.0364770453562	86.477548837582	4.2936706692732

Commentaire :

Les valeurs des paramètres de dispersion qu'on a trouvés nous montrent qu'il y a une dispersion des données, la médiane de notre distribution est : 3.09839680914, ceci montre que 50 % des valeurs sont inférieures à 3.09839680914.

Question2

Q2.1

Considérons l'échantillon qui est donné par $\{X_1, X_2, \dots, X_n\}$

le logiciel R nous sert à calculer $\{L_k\}, \{Y_k\}, N_n$

Le Code sur logiciel R pour calculer $\{L_k\}$ est donné par :

```
> L=c()
> i<-1
> j<-2
> while(j<=n){
+ L<-c(L,i)
+ while(x[j]<x[i]){
+ j<-j+1
+ if(j>n){break}
+ }
+ i<-j
+ j<-j+1
```

```
+ }
> L
```

on prend $n=500$,On exécute ce code sur les données on obtient les résultats suivants :

```
[1] 1 2 3
```

Le Code sur logiciel R pour calculer $\{Y_k\}$ est donné par :

```
> Y=c()
> for(t in L){
+ Y<-c(Y,x[t])}
> for(t in Y){
+ print (t)}
```

On exécute ce code sur les données on obtient les résultats suivants :

```
[1] 3.2160672312851
```

```
[1] 10.798281441256
```

```
[1] 86.553501166412
```

Code sur logiciel R pour calculer $\{N_n\}$

calculon $(I_k)_{k \geq 1}$:

Le Code sur logiciel R pour calculer $\{I_k\}$ est donné par :

```
> I<-rep(0,n)
> I[1]<-1
> for(k in 2 :n){
+ if(x[k]>max(x[1 :(k-1)]))
+ I[k]<-1
+ }
> I
```

On calcule N_n :

LE code sur R pour calculer N_n est :

```
> Nn<-sum(I)
> Nn
on trouve
 $N_n = 3$ 
```

Q2.2

Montrons que $\{I_k\}_{k \geq 1}$ est une suite de v.a. indépendantes :

$I_1, \dots, I_n$ sont indépendantes si et seulement si

$$F_{(I_1, \dots, I_n)} = \prod_{k=1}^n F_{I_k}(x)$$

avec F est la fonction de répartition.

$$\text{On a : } F_{1_A}(x) = \begin{cases} 1 & \text{si } x \geq 1. \\ P(\bar{A}) = 1 - P(A) & \text{si } 0 \leq x \leq 1. \\ 0 & \text{si } x < 0 \end{cases}$$

1^{er} cas : ($x < 0$)

On a $F_{I_k}(x) = 0 \quad \forall k \in [1; n]$

Il s'en suit que : $\prod_{k=1}^n F_{I_k}(x) = 0$

et on a $F_{(I_1, \dots, I_n)}(x) = P(\cap k = 1^n I_k \leq x)$

$$= P((I_1 \leq x) \cap \dots \cap (I_n \leq x))$$

$$= P(\emptyset \cap \dots \cap \emptyset)$$

$$= P(\emptyset)$$

$$= 0$$

Donc $F_{(I_1, \dots, I_n)} = \prod_{k=1}^n F_{I_k}(x) \quad (*)$

2^{ème} cas : ($x \geq 1$)

On a $F_{I_k}(x) = 1, \forall k \in [1; n]$

Il s'en suit que : $\prod_{k=1}^n F_{I_k}(x) = 1$

et on a $F_{(I_1, \dots, I_n)}(x) = P(\cap k = 1^n I_k \leq x)$

$$= P((I_1 \leq x) \cap \dots \cap (I_n \leq x))$$

$$= P(\Omega \cap \dots \cap \Omega)$$

$$= P(\Omega) = 1$$

Donc $F_{(I_1, \dots, I_n)}(x) = \prod_{k=1}^n F_{I_k}(x) \quad (* *)$

3^{ème} cas : ($0 \leq x \leq 1$)

On a $F_{I_k} = 1 - P(X_k > \max\{X_1, \dots, X_{k-1}\})$, $\forall k \in [1; n]$

Donc $\prod_{k=1}^n F_{I_k}(x) = F_{I_1}(x) \times \prod_{k=2}^n F_{I_k}(x)$

$$= (1 - P(I_1 = 1)) \times \prod_{k=2}^n F_{I_k}(x)$$

$$= 0 \quad (\text{car } P(I_1 = 1) = 1)$$

et on a $F_{(I_1, \dots, I_n)}(x) = P(\cap k = 1^n I_k \leq x)$

$$\begin{aligned}
&= P((I_1 \leq x) \cap (I_2 \leq x) \cap \dots \cap (I_n \leq x)) \\
&= P(\emptyset) \\
&= 0
\end{aligned}$$

Donc $F_{(I_1, \dots, I_n)}(x) = \prod_{k=1}^n F_{I_k}(x)$ (* * *)

D'après (*), (**) et (* * *) on a :

$$F_{(I_1, \dots, I_n)}(x) = \prod_{k=1}^n F_{I_k}(x)$$

On déduit que : $\{I_k\}_{1 \leq k \leq n}$ est une suite de variables aléatoires indépendantes.

Ainsi : $\{I_k\}_{k \geq 1}$ est une suite de variables aléatoires indépendantes.

Montrons que $I_k \sim \text{Ber}(\frac{1}{k})$:

On a $I_k = 1\{X_k > \max(X_1, \dots, X_{k-1})\}$.

$$\text{Alors } I_k = \begin{cases} 1 & \text{si } X_k > \max(X_1, \dots, X_{k-1}). \\ 0 & \text{sinon.} \end{cases}$$

Donc I_k suit une loi de bernoulli de paramètre p à déterminer.

On a $p = P(I_k = 1) = P(X_k > \max(X_1, \dots, X_{k-1})) = P(X_k = \max(X_1, \dots, X_k)) = \frac{1}{k}$
D'où $I_k \sim \text{Ber}(\frac{1}{k})$.

Q2.3

Montrons que $\frac{N_n}{\log(n)} \xrightarrow[n \rightarrow +\infty]{p.s.} 1$:

D'après la loi forte des grandes nombres :

Pour tout $n \in \mathbb{N}^* - \{1\}$

On pose (Z_n) suite des variables aléatoires tel que

$$Z_n = \frac{nI_n}{\log(n)}$$

On a $\{I_k\}_{k \geq 1}$ est une suite de variables aléatoires indépendantes, alors $\{Z_k\}$ l'est aussi.
on a

$$\frac{1}{n} \sum_{k=1}^n Z_k = \frac{\sum_{k=1}^n I_k}{\log n} = \frac{N_n}{\log n}$$

Montrons que ; $E(Z_n) \xrightarrow{n \rightarrow +\infty} 1$:

On a

$$E\left(\frac{N_n}{\log n}\right) = \frac{1}{\log n} E(N_n)$$

$$= \frac{1}{\log n} E\left(\sum_{k=1}^n I_k\right)$$

Puisque $I_k \sim \text{Ber}\left(\frac{1}{k}\right)$ alors
 $E(I_k) = \frac{1}{k}$

$$\begin{aligned} E\left(\frac{N_n}{\log n}\right) &= \frac{1}{\log n} E\left(\sum_{k=1}^n I_k\right) \\ &= \frac{1}{\log n} \sum_{k=1}^n \frac{1}{k} \end{aligned}$$

et on a :

$$(\forall x > 0) \frac{1}{1+x} \leq \log(1+x) - \log(x) \leq \frac{1}{x}$$

$$\implies \log(1+n) \leq \sum_{k=1}^n \frac{1}{k} \quad (*)$$

$$\text{et } \sum_{k=1}^n \frac{1}{1+k} \leq \log(1+n)$$

$$\iff \left(\sum_{k=1}^n \frac{1}{k}\right) + 1 + \frac{1}{1+n} \leq \log(1+n)$$

$$\implies \left(\sum_{k=1}^n \frac{1}{k}\right) \leq \log(1+n) - 1 - \frac{1}{1+n} \quad (**)$$

D'après (*) et (**) on a :

$$\log(1+n) \leq \sum_{k=1}^n \frac{1}{k} \leq \log(1+n) - 1 - \frac{1}{1+n}$$

$$\text{Alors } \frac{\log(1+n)}{\log n} \leq \frac{E(N_n)}{\log n} \leq \frac{\log(1+n)}{\log(n)} - \frac{1}{\log(n)} - \frac{1}{(1+n)\log n}$$

$$\text{On sait que } \lim_{n \rightarrow +\infty} \frac{\log(1+n)}{\log(n)} = 1$$

$$\text{car } (\log(n) \sim \log(1+n))$$

$$\text{Ainsi } \lim_{n \rightarrow +\infty} E\left(\frac{N_n}{\log(n)}\right) = 1$$

$$\text{D'où } \frac{1}{n} \sum_{k=1}^n Z_k \xrightarrow[n \rightarrow +\infty]{p.s} 1 :$$

C'est à dire $\frac{N_n}{\log(n)} \xrightarrow[n \rightarrow +\infty]{p.s.} 1$:

Montrons que $\frac{(N_n - \log n)}{\sqrt{\log n}} \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, 1)$:

D'après le théorème de la limite centrale on a :

$$\frac{N_n - nE(I_k)}{\sqrt{n \operatorname{var}(I_k)}} \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, 1)$$

$$\text{Alors } \frac{N_n - E(N_n)}{\sqrt{\operatorname{var}(N_n)}} \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, 1)$$

$$\text{Or } \operatorname{var}(N_n) = \sum_{k=1}^n \frac{1}{k} \left(1 - \frac{1}{k}\right)$$

$$= \sum_{k=1}^n \frac{1}{k} - \sum_{k=1}^n \frac{1}{k^2}$$

$$\text{On sait que } \sum_{k=1}^n \frac{1}{k} = \log n + \gamma + \frac{1}{2n^2} + o\left(\frac{1}{2n^2}\right) \text{ et } \sum_{k=1}^n \frac{1}{k^2} = \frac{\pi^2}{6}$$

$$\text{Donc } \operatorname{var}(N_n) = \log n + \gamma + \frac{1}{2n^2} + o\left(\frac{1}{2n^2}\right) - \frac{\pi^2}{6}$$

Alors

$$\frac{N_n - \left(\log n + \gamma + \frac{1}{2n^2} + o\left(\frac{1}{2n^2}\right)\right)}{\sqrt{\log n + \gamma + \frac{1}{2n^2} + o\left(\frac{1}{2n^2}\right) - \frac{\pi^2}{6}}} \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, 1)$$

Ainsi

$$\frac{(N_n - \log n)}{\sqrt{\log n}} \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, 1)$$

Q2.5

Montrons que $\hat{n} = 2^{N_n} - 1$ est un estimateur sans biais de n :

$$\text{On a } E(\hat{n}) = E(2^{N_n}) - 1$$

$$= E(2^{\sum_{k=1}^n I_k}) - 1$$

$$= E(\prod_{k=1}^n 2^{I_k}) - 1$$

$$= \prod_{k=1}^n E(2^{I_k}) - 1 \quad \text{car } I_1, I_2, \dots, I_n \text{ sont indépendants.}$$

$$\text{Or } E(2^{I_k}) = 2^0 P(I_k = 0) + 2^1 P(I_k = 1)$$

$$\text{Puisque } I_k \sim \operatorname{Ber}\left(\frac{1}{k}\right)$$

$$\text{Alors } E(2^{I_k}) = \frac{k-1}{k} + 2 \times \frac{1}{k} = \frac{k+1}{k}$$

$$\begin{aligned}
\text{Alors } E(\hat{n}) &= \prod_{k=1}^n \frac{k+1}{k} - 1 \\
&= \frac{2}{1} \times \frac{3}{2} \times \dots \times \frac{n+1}{n} - 1 \\
&= n + 1 - 1
\end{aligned}$$

Donc $E(\hat{n}) = n$

Il s'en suit que : $\hat{n}$ est un estimateur sans biais de n .

Calculons la variance de $\hat{n}$:

$$\begin{aligned}
\text{On a } \text{var}(\hat{n}) &= \text{var}(2^{N_n} - 1) = E((2^{N_n})^2) - (E(2^{N_n}))^2 \\
&= E(2^{2N_n}) - (E(2^{N_n}))^2
\end{aligned}$$

$$\text{Or } E(2^{2N_n}) = E(2^{\sum_{k=1}^n 2I_k}) = E(\prod_{k=1}^n 2^{2I_k})$$

Puisque $I_1, \dots, I_n$ sont indépendants.

$$\text{Alors } E(2^{2N_n}) = \prod_{k=1}^n E(2^{2I_k})$$

$$\text{De plus } E(2^{2I_k}) = 2^{2 \times 1} P(I_k = 1) + 2^{2 \times 0} P(I_k = 0)$$

$$\begin{aligned}
&= 4 \times \frac{1}{k} + \frac{k-1}{k} \\
&= \frac{k+3}{k}
\end{aligned}$$

$$\begin{aligned}
\text{Donc } E(2^{2N_n}) &= \prod_{k=1}^n \frac{k+3}{k} \\
&= \frac{(n+1)(n+2)(n+3)}{6}
\end{aligned}$$

$$\text{puisque } E(\hat{n}) = n = E(2^{N_n}) - 1 \text{ alors } E(2^{N_n}) = n + 1$$

$$\text{Ainsi } \text{var}(\hat{n}) = \frac{(n+1)(n+2)(n+3)}{6} - (n + 1)^2.$$

Question3

Pour chaque loi classique, on choisit arbitrairement un jeu de paramètres θ et on trace la densité correspondante (on trace les courbes sur deux graphes : 4 sur chacun).

— On propose les commandes sur R :

```

> x<-seq(0,5,.01)
> y<-dlnorm(x,1, 1)
> y2 <- dgamma(x, 4, 1)


```

```

> y3<-dweibull(x,3,3)
> y4<- dbeta(x,3,3)
> leg.txt <- c("LN(1,1)","G( 4, 1)","W(3,3)","B(3,3)")
> plot(x, y, xlab="x", ylab="f(x)", main="les densités",
+ ylim=range(y, y2, y3, y4), col="black", type="l")
> lines(x,y2, lty=2)
> lines(x,y3, lty=3)
> lines(x,y4, lty=4)
> legend("topright",leg=leg.txt, col="black",lty=1 :4)

```

— Cela renvoie :




— On propose les commandes sur R :

```

> x<-seq(0,5,.01)
> y <- dnorm(x, 1, 1)
> y2<-dlogis(x,3, 2)
> y3<-dcauchy(x,3, 4)
> y4<-dpareto(x,2, 4)
> leg.txt <- c("N(1, 1)","L( 3, 2)","C(3, 4)","P(2, 4)")
> plot(x, y, xlab="x", ylab="f(x)", main="les densités",
+ ylim=range(y, y2, y3, y4), col="black", type="l")
> lines(x,y2, lty=2)
> lines(x,y3, lty=3)
> lines(x,y4, lty=4)
> legend("topright",leg=leg.txt, col="black",lty=1 :4)

```

— Cela renvoie :




Question4

— histogramme des données :

On propose les commandes sur R :

```
> hist(x,main="histogramme des données")
```

Cela renvoie :




— Graphe de la fonction de répartition empirique :

On propose les commandes :

```
> plot(ecdf(x),main="la fonction de répartition")
```

Cela renvoie :



— Élimination des lois :

On trace la fonction de répartition correspondante pour chaque loi et la fonction de répartition empirique et on les compare


— Pour la loi bêta :

On propose les commandes sur R :

```
> plot(ecdf(x), main = "Méthode de la fonction de répartition (loi bêta) ")
```

```
> curve(pbeta(x, 3,3), add = TRUE,col="red")
```

Cela renvoie :




— Pour la loi logistique :

On propose les commandes sur R :

```
> plot(ecdf(x), main = "Méthode de la fonction de répartition (loi logistique) ")
```

```
> curve(plogis(x, 3,2), add = TRUE,col="red")
```

Cela renvoie :




— Pour la loi gamma :

On propose les commandes sur R :

```
> plot(ecdf(x), main = "Méthode de la fonction de répartition (gamma) ")
```

```
> curve(pgamma(x,4,1), add = TRUE,col="red")
```

Cela renvoie :




— Pour la loi normale :

On propose les commandes sur R :

```
> plot(ecdf(x), main = "Méthode de la fonction de répartition (normale) ")
```

```
> curve(pnorm(x,1,1), add = TRUE,col="red")
```

Cela renvoie :




— Pour la loi log-normale :

On propose les commandes sur R :

```
> plot(ecdf(x), main = "Méthode de la fonction de répartition (log-normale) ")
```

```
> curve(plnorm(x,1,1), add = TRUE,col="red")
```

Cela renvoie :




— Pour la loi de Weibull :

On propose les commandes sur R :

```
> plot(ecdf(x), main = "Méthode de la fonction de répartition (de Weibull) ")
```

```
> curve(pweibull(x,3,3), add = TRUE,col="red")
```

Cela renvoie :




— Pour la loi de Cauchy :

On propose les commandes sur R :

```
> plot(ecdf(x), main = "Méthode de la fonction de répartition (loi de Cauchy) ")
```

```
> curve(pcauchy(x,3,4), add = TRUE,col="red")
```

Cela renvoie :




— Pour la loi de Pareto :

On propose les commandes sur R :

```
> plot(ecdf(x), main = "Méthode de la fonction de répartition (loi de Pareto) ")
```

```
> curve(ppareto(x,2,4), add = TRUE,col="red")
```

Cela renvoie :



- Commentaire : On élimine les lois suivantes : la loi bêta, la loi logistique, la loi normale, la loi weibull, et la loi de cauchy, car pour chaque loi la courbe de la fonction de répartition n'ajuste pas la courbe de la fonction de répartition empirique.

Question 5

- Estimation des paramètres en donnant les détails de ces estimateurs et leurs qualités.

- Pour la loi log-normale

- On propose les commandes sur R :

```
> para.lnorm<-fitdist(x,distr = "lnorm",method = "mle")
> summary(para.lnorm)
```

Cela renvoie :

```
Fitting of the distribution 'lnorm' by maximum likelihood
Parameters :
      estimate      Std. Error
meanlog 1.111145750615 0.045577931014519
sdlog    1.0191535202425 0.032228324465325
Loglikelihood: -1274.5127544522   AIC: 2553.0255089044   BIC: 2561.4547251012
Correlation matrix:
      meanlog sdlog
meanlog      1      0
sdlog        0      1
```

- Pour la loi gamma :

- On propose les commandes sur R :

```
> para.gama<-fitdist(x,distr = "gamma",method = "mle")
> summary(para.gama)
```

Cela renvoie :

```
Fitting of the distribution 'gamma' by maximum likelihood
Parameters :
      estimate      Std. Error
shape 1.10084015501876 0.061817540370658
rate   0.21571640275688 0.015207409889926
Loglikelihood: -1313.4466670222   AIC: 2630.8933340445   BIC: 2639.3225502413
Correlation matrix:
      shape      rate
shape 1.00000000000000 0.79652575056195
rate  0.79652575056195 1.00000000000000
```

— Pour la loi de Pareto :

— On propose les commandes sur R :

```
> para.pareto<-fitdist(x,"pareto",start =list(shape=min(x),scale=1))  
> summary(para.pareto)
```

Cela renvoie :

```
Fitting of the distribution ' pareto ' by maximum likelihood  
Parameters :  
      estimate      Std. Error  
shape  6.09528322254024  1.59769143761412  
scale 25.72917761620231  7.73554588299175  
Loglikelihood: -1302.09623381604   AIC:  2608.19246763208   BIC:  2616.62168382893  
Correlation matrix:  
      shape      scale  
shape 1.000000000000000  0.985337854796232  
scale 0.985337854796232  1.000000000000000
```


Histogramme des données et courbes des densités

— Pour Loi gamma

— On propose les commandes sur R :

```
> hist(x,freq = FALSE,main="histogramme et densité de la loi gamma",ylab = "")  
> curve(dgamma(x,1.10084015501876,0.21571640275688),add = TRUE)
```

Cela renvoie :




— Pour la Loi de Pareto

— On propose les commandes sur R :

```
> hist(abs(x),freq = FALSE,main="histogramme et densité de la loi de Pareto",ylab = "")  
> curve(dpareto(abs(x), 6.09528322254024, 25.72917761620231),add = TRUE)
```

Cela renvoie :




— Pour la Loi log-normale

— On propose les commandes sur R :

```
> hist(x,freq = FALSE,main="histogramme et densité de la loi gamma",ylab = "")
> curve(dlnorm(x,1.111145750615,1.0191535202425),add = TRUE)
```

Cela renvoie :



Commentaire :

La courbe de la densité de la loi log-normale convient à l'histogramme des données, donc il est possible d'utiliser ce loi pour mieux estimer la fonction densité de la variable aléatoire X .


Question6

— Approximation de la densité par la méthode du noyau :

— On propose les commandes sur R :

```
> plot(density(x),main = "Noyaux")
```

Cela renvoie :



— Explication de la méthode du noyau :

Les informations "N = 500 Bandwidth = 0.8321" précisent des quantités utilisées dans l'estimateur de la densité : c'est un estimateur dit "à noyau", lequel utilise une fenêtre (Bandwidth) qui s'ajuste en fonction des données.

Question7

La méthode de QQ plot (quantile-quantile plot) consiste à la comparaison des quantiles empirique et des quantiles théorique.


Pour chaque loi classique on trace le QQ-plot correspondant

— pour la loi de gamma :

— Code sur logiciel R

```
> plot(qgamma(ppoints(x),4, 1), sort(x), main = "QQ plot Pour la loi gamma",
+ xlab = "")
> abline(0,x, col = "red")
```


— Resultats du code :



— Pour la loi de normale :

— Code sur logiciel R
`> qqnorm(x, main="QQ plot pour la loi normale")`
`> abline(0,x, col = "red")`


— Resultats du code :



— Pour la loi de cauchy :

— Code sur logiciel R
`> plot(qcauchy(ppoints(x), 3, 4), sort(x), main = " QQ plot pour la loi cauchy",`
`+ xlab = "")`
`> abline(0,x, col = "red")`

— Resultats du code :




— Pour la loi log-normale :

— Code sur logiciel R

```
> plot(qlnorm(ppoints(x), 4, 9), sort(x), main = "QQ plot pour la loi log-normale",
+ xlab = "")
> abline(0,x, col = "red")
```

— Resultats du code :




— Pour la loi de Weibull :

— Code sur logiciel R

```
> plot(qweibull(ppoints(x), 3, 3), sort(x), main = "QQ plot pour la loi weibull",
+ xlab = "")
> abline(0,x, col = "red")
```

— Resultats du code :




— Pour la loi bêta :

— Code sur logiciel R

```
> plot(qbeta(ppoints(x), 3,3), sort(x), main = "QQ plot pour la loi beta",
+ xlab = "")
> abline(0,x, col = "red")
```

— Resultats du code :




— Pour la loi logistique :

— Code sur logiciel R

```
> plot(qlogis(ppoints(x), 3, 2), sort(x), main = "QQ plot Pour la loi logistique",
+ xlab = "")
> abline(0,x, col = "red")
```

— Resultats du code :




— Pour la loi de pareto :

— Code sur logiciel R

```
> plot(qpareto(ppoints(x), 2, 4), sort(x), main = "QQ plot Pour la loi pareto",
+ xlab = "")
> abline(0,x, col = "red")
```

— Resultats du code :



Commentaire :

la seule droite qui ajuste bien le nuage de points concerne la loi log-normale ,alors on peut affirmer que X suit la loi log-normale .

Question8

Pour savoir la loi de X ,on effectue le test de Kolmogorov-Smirnov pour les lois qu'on a pas

éliminées auparavant, on prend $\alpha = 0.05$.

on considère les hypothèses :

$$\begin{cases} H_0 : "X \text{ suit la loi gamma}" \text{ contre} \\ H_1 : "X \text{ ne suit pas la loi gamma}" \end{cases}$$
$$\begin{cases} H_0 : "X \text{ suit la loi de Pareto}" \text{ contre} \\ H_1 : "X \text{ ne suit pas la loi de Pareto}" \end{cases}$$

$$\begin{cases} H_0 : "X \text{ suit la loi log-normale}" \text{ contre} \\ H_1 : "X \text{ ne suit pas la loi log-normale}" \end{cases}$$

On propose les commandes sur R :

```
> a<-x
> b<-rgamma(x,1.10084015501876,0.21571640275688)
> c<-rpareto(x,6.0952832225402,25.7291776162023)
> d<-rlnorm(x,1.1111145750615, 1.0191535202425)
> ks.test(a,b)
> ks.test(a,c)
> ks.test(a,d)
```

Cela renvoie :

```
      . . .

Two-sample Kolmogorov-Smirnov test

data:  a and b
D = 0.106, p-value = 0.0072637949426
alternative hypothesis: two-sided

Two-sample Kolmogorov-Smirnov test

data:  a and c
D = 0.156, p-value = 1.0388066948e-05
alternative hypothesis: two-sided

Two-sample Kolmogorov-Smirnov test

data:  a and d
D = 0.044, p-value = 0.7183793593
alternative hypothesis: two-sided
```

- Pour la loi log-normale , pour $\alpha = 0.05$, on remarque que $p\text{-value} > 0.05$,donc on accepte l'hypothèses H_0 .
- Pour la loi de Pareto , pour $\alpha = 0.05$, on remarque que $p\text{-value} < 0.05$,donc on rejette l'hypothèses H_0 .
- Pour la loi gamma ,pour $\alpha = 0.05$, on remarque que $p\text{-value} < 0.05$,donc on rejette l'hypothèses H_0 .

D'après le Test de Kolmogorov-Smirnov pour un risque $\alpha = 0.05$,la variable aléatoire X suit la loi log-normale

Question9

— Résumé de cette étude :

Les méthodes graphiques comme la méthode de l'histogramme, la méthode de la fonction de répartition et la méthode du QQ-plot nous servent à étudier l'adéquation d'une variable aléatoire X avec une loi donnée : et pour confirmer on peut utiliser les tests statistiques, comme le test de Kolmogorov-Smirnov.

Le tableau suivant résume pour chaque loi classique les raisons pour lesquelles on a pris notre décision :

loi	Méthode de la fonction de répartition	Méthode du QQ-plot	Méthode de l'histogramme
de Cauchy	la courbe de la fonction de répartition et la courbe de la fonction de répartition empirique de cette loi ne sont pas similaires	la droit n'ajuste pas le nuage de points	
de Pareto	la courbe de la fonction de répartition et la courbe de la fonction de répartition empirique de cette loi sont similaires	la droit n'ajuste pas le nuage de points	la fonction densité de ce loi ne convient pas à l'histogramme des données
bêta	la courbe de la fonction de répartition et la courbe de la fonction de répartition empirique de cette loi ne sont pas similaires	la droit n'ajuste pas le nuage de points	
de Weibull	la courbe de la fonction de répartition et la courbe de la fonction de répartition empirique de cette loi ne sont pas similaires	la droit n'ajuste pas le nuage de points	
log-normale	la courbe de la fonction de répartition et la courbe de la fonction de répartition empirique de cette loi sont similaires	la droit ajuste bien le nuage de points	la fonction densité de ce loi convient à l'histogramme des données
normale	la courbe de la fonction de répartition et la courbe de la fonction de répartition empirique de cette loi ne sont pas similaires	la droit n'ajuste pas le nuage de points	
gamma	la courbe de la fonction de répartition et la courbe de la fonction de répartition empirique de cette loi sont similaires	la droit n'ajuste pas le nuage de points	la fonction densité de ce loi ne convient pas à l'histogramme des données
logistique	la courbe de la fonction de répartition et la courbe de la fonction de répartition empirique de cette loi ne sont pas similaires	la droit n'ajuste pas le nuage de points	

D'après les Méthode graphiques et le test de kolmogorov-smirnov les données sont adéquates à la loi log-normale de paramètres :

meanlog : 1.1111145750615

sdlog : 1.0191535202425

