

Statistique d'ordre et identification d'une loi avec R

Projet académique de Master — 2020

Contexte et objectif

Le projet étudie un échantillon de 500 observations afin d'identifier une loi de probabilité classique compatible avec les données. Il associe une première partie théorique sur les records à une étude statistique menée avec R.

Problématique

Comment décrire l'échantillon, comparer plusieurs familles de lois, estimer leurs paramètres et retenir un modèle défendable sans confondre qualité d'ajustement et preuve absolue ?

Démarche

- Calcul des statistiques descriptives : position, dispersion, quartiles, étendue et écart interquartile.
- Construction des indicatrices de records, identification de leurs positions et étude du nombre de records.
- Comparaison de lois bêta, logistique, gamma, normale, log-normale, Weibull, Pareto et Cauchy.
- Inspection par histogramme, fonctions de répartition empiriques, densités ajustées et QQ-plots.
- Estimation des paramètres des modèles candidats, puis vérification par un test d'adéquation.

Résultat du rapport initial

Les diagnostics graphiques convergent vers la loi log-normale. Le rapport estime ses paramètres puis utilise le test de Kolmogorov-Smirnov pour comparer ce modèle aux alternatives encore retenues. Pour le jeu de données étudié, la loi log-normale est la conclusion privilégiée.

Amélioration et reproductibilité

Le dépôt contient une réécriture structurée du code R. Elle sépare le chargement, les statistiques descriptives, l'estimation, les graphiques et le test. Pour tenir compte du fait que les paramètres log-normaux sont estimés sur les mêmes données, le script propose une p-value obtenue par bootstrap paramétrique avec réestimation à chaque réplication.

Compétences démontrées

- Transformer une question probabiliste en étapes de calcul et de validation.
- Programmer une chaîne d'analyse reproductible sous R.
- Comparer des modèles par plusieurs diagnostics complémentaires.
- Interpréter un test statistique avec prudence et expliciter ses limites.

Limites

Les données originales ne sont pas publiées, leurs droits de diffusion n'étant pas établis. La sélection d'une loi dépend du jeu de données, des hypothèses du modèle et de la stratégie de validation. Une p-value élevée ne prouve pas qu'un modèle est vrai ; elle indique seulement que l'écart observé n'est pas incompatible avec le modèle au niveau considéré.